

چارچوب گراف زمانی برای کشف فرصت رشد تراکنش پذیرندگان و اولویت‌بندی کمپین

سعید علی اکبری^{۱*}، سعید شاهسون^۲

^۱ کارشناس هوش تجاری، شرکت رایامیت، تهران، ایران (نویسنده مسئول)

saeed.aliakbari@rayamate.ir

^۲ معمار نرم‌افزار، شرکت رایامیت، تهران، ایران

saeed.shahsavan@rayamate.ir

چکیده

شرکت‌های ارائه‌دهنده خدمات پرداخت روزانه حجم انبوهی از سوابق تراکنشی را پردازش می‌نمایند. رویکردهای سنتی مدیریت پذیرندگان بر شاخص‌های خلاصه‌شده جدولی نظیر حجم کل یا مدل RFM استوار بوده و نسبت به شبکه تعاملات مشتریان نابینا هستند؛ در نتیجه قادر به تفکیک افت طبیعی از ظرفیت بالقوه رشد نیستند. در این مقاله، چارچوب گراف زمانی HAMTA ارائه می‌شود که موتور رتبه‌بندی فرصت‌های رابطه‌ای را با حفظ‌های کنترل ریسک عملیاتی تلفیق می‌نماید. HAMTA صرفاً بر پایه پنج فیلد تراکنشی استاندارد، جریان تراکنش‌ها را به گراف دویخشی کارت-پذیرنده تبدیل کرده و ساختار همپایان را از طریق اشتراک مشتریان، تجانس صنف و انحنای فرم-ریچی استخراج می‌کند. سپس با مدل توجه گراف زمانی، تابع درست‌نمایی دوجمله‌ای منفی و واسنجی زمانی بازه پیش‌بینی، کران بالای عملکرد و پنج‌مارک همپایان تخمین زده شده و شاخص M-GATO جهت اولویت‌بندی کمپین محاسبه می‌گردد. ارزیابی تجربی بر روی ۳۵۰۰۰ تراکنش شبیه‌سازی‌شده طی ۱۰ سید تصادفی نشان می‌دهد HAMTA با ثبت خطای میانگین ۴/۴۸ تراکنش و دقت رتبه‌بندی ۳۶/۶ درصد، به بهبود ۲/۴۶ برابری نسبت به شانس تصادفی کل سید (و ۲/۱۰ برابری نسبت به جامعه کاندیداها) دست یافته و زیرساختی عملیاتی و بدون برچسب مداخله برای هوشمندی سید پذیرندگان فراهم می‌سازد.

چارچوب HAMTA تنها یک مدل یادگیری ماشین نیست، بلکه یک مؤلفه تصمیم‌یار (Decision-support component) در معماری مدیریت پذیرندگان است. این معماری از جریان داده‌های تراکنشی آغاز شده، در لایه هوشمندی گراف پردازش می‌گردد و توسط موتور تصمیم‌گیری M-GATO به واحد بازاریابی جهت اجرای کمپین و دریافت بازخورد سازمانی متصل می‌شود.

کلمات کلیدی

سامانه‌های پرداخت، شبکه‌های عصبی گراف زمانی، هوشمندی پذیرندگان، اولویت‌بندی کمپین، واسنجی بازه پیش‌بینی، انحنای فرم-ریچی، فین‌تک.

نسبی بدون نیاز به برچسب‌های تاریخی مداخله بر پایه گراف تراکنش زمانی و پنج‌مارک محافظه‌کارانه ارائه می‌کند.

2. کارهای مرتبط

2.1. شبکه‌های عصبی گراف در تحلیل‌های مالی

شبکه‌های عصبی گراف (GNN) با مدل‌سازی موجودیت‌ها به عنوان گره و تراکنش‌ها به عنوان یال، در کشف تقلب و تحلیل حساب‌های مشکوک موفقیت چشمگیری داشته‌اند [9-11]. معماری‌های پایه نظیر اتوانکودرهای تغییراتی گراف [12] و ساختارهای استقرایی شبکه تراکنشی [13] چارچوب‌های بازنمایی ساختار را توسعه داده‌اند [14, 15]. در حوزه بازاریابی پرداخت، لیو و همکاران (CIKM 2019) [9] از یادگیری بازنمایی گراف جهت بهینه‌سازی مشوق‌ها در علی‌پی بهره بردند؛ اما رویکرد آن‌ها متکی بر لاگ‌های پیشین مداخله و کوپن‌های تشویقی است. در مقابل، سوییچ‌های شاپرکی فاقد برچسب‌های مداخله بوده و نیازمند اولویت‌بندی فرصت‌ها در داده‌های مشاهده‌ای هستند.

2.2. یادگیری نمایش در گراف‌های پویا و زمانی

روابط مالی ذاتاً متغیر با زمان هستند. مدل‌های گراف زمانی نظیر TGAT [16]، [17] TGN [18] و EvolveGCN [19] با به‌کارگیری مکانیزم‌های توجه زمانی و پروتکل‌های حفظ تقدم زمانی، مانع از نشت اطلاعات آینده به گذشته شده و پویایی نرخ تراکنش‌ها را مدل‌سازی می‌کنند.

2.3. تحلیل شبکه پذیرندگان و انحنای فرم-ریچی

در شبکه‌های تراکنشی مالی، گره‌ها خوشه‌بندی‌های متراکم و گلوگاه‌های ساختاری تشکیل می‌دهند [20, 21]. انحنای فرم-ریچی [4, 5] با اندازه‌گیری اشتراک همسایگی‌ها و تمایز پیوندهای پل‌ساز، به عنوان تنظیم‌کننده ساختاری و مهارکننده پدیده فشردگی اطلاعات (Over-squashing) در گراف عمل می‌کند [6, 7, 22].

2.4. تخمین نااطمینانی و واسنجی بازه پیش‌بینی

پیش‌بینی‌های نقطه‌ای قادر به تفکیک نوسانات تصادفی طبیعی از افت معنادار عملکرد نیستند. روش‌های واسنجی بازه پیش‌بینی تجربی [8] و پژوهش‌های نااطمینانی پیش‌بینی بر روی گراف‌های زمانی [23] با سنجش توزیع خطاهای پسماند در پنجره‌های گذشته، کران‌های بازه‌ای واسنجی‌شده را استخراج می‌نمایند؛ لذا در HAMTA واسنجی بازه پیش‌بینی یک‌طرفه زمانی (One-sided temporal prediction-interval calibration) به صورت تجربی صورت می‌گیرد.

2.5. تحلیل مرز تصادفی و مدل‌های داده‌های شمارشی

در ادبیات اقتصادسنجی، تحلیل مرز تصادفی (SFA) کارایی نسبی بنگاه‌ها را نسبت به مرز بهترین عملکرد تجربی برآورد می‌نماید [24]. در داده‌های تراکنش خرد، به دلیل بیش‌پراکندگی شدید، استفاده از توزیع دوجمله‌ای منفی مانع از ارب

شبکه‌های پرداخت کارتی، سوییچ‌های بین‌بانکی و شرکت‌های ارائه‌دهنده خدمات پرداخت (PSP) روزانه صدها میلیون تراکنش را بر روی پایانه‌های فروش و درگاه‌های اینترنتی ثبت می‌کنند [1, 2]. در سامانه‌های سنتی مدیریت پذیرندگان، اولویت‌بندی بازاریابی عموماً بر اساس شاخص‌های گذشته‌نگر جدولی نظیر ارزش ناخالص تسویه یا مدل‌های RFM استوار است [3]. با این حال، این رویکردها تفاوت سه مفهوم بنیادین را نادیده می‌گیرند: «کمترین حجم تراکنش» با «عملکرد ضعیف نسبت به همپایان» و «فرصت رشد در کمپین» یکسان نیست. برای نمونه، پذیرنده‌ای با ۵۰ تراکنش که تمامی همپایان آن در همان صنف و بافت تعاملات مشتریان مشترک نیز حدود ۵۰ تراکنش دارند، در وضعیت طبیعی فعالیت می‌کند؛ اما پذیرنده‌ای با ۱۰۰ تراکنش که همپایان همساختار آن به طور میانگین ۱۸۰ تراکنش ثبت کرده‌اند، واجد یک شکاف عملکردی نسبی معنادار است. هدف اصلی این مقاله، کشف پذیرنده‌ای نیست که صرفاً کمترین حجم مطلق را دارد، بلکه کشف پذیرندگانی است که نسبت به همپایان مشابه خود، واجد شکاف عملکرد ساختاری در داده‌های مشاهده‌ای هستند.

شناسایی پذیرندگان کم‌عملکرد اما دارای پتانسیل بالا، با چهار چالش اساسی روبروست: نخست، نابینایی رابطه‌ای مدل‌های جدولی نسبت به ساختار مشتریان مشترک پایانه‌ها؛ دوم، بیش‌پراکندگی شدید داده‌های شمارشی تعداد تراکنش که برآزش با خطای گوسی را ناکارآمد می‌سازد؛ سوم، تفاوت پیش‌بینی ایزرسی آینده با کشف فرصت، چرا که پیش‌بینی استاندارد صرفاً تداوم کم‌عملکردی پذیرنده ضعیف را تخمین می‌زند؛ و چهارم، لزوم اتکای انحصاری بر پنج فیلد استاندارد دفتر کل بدون هیچ‌گونه فرضیات خارجی: شناسه کارت (Masked PAN)، مبلغ تراکنش (Amount)، شناسه پذیرنده دفتر کل PSP، تاریخ و زمان (Create Date) و صنف اقتصادی (Cast Name).

برای حل این چالش‌ها، چارچوب هوش مصنوعی گراف زمانی با نام HAMTA در قالب یک معماری سه‌لایه ارائه می‌گردد: موتور رتبه‌بندی فرصت‌های رابطه‌ای، حافظه‌های کنترل ریسک عملیاتی و پایالایس ساختاری توپولوژیک. کارت‌ها صرفاً به عنوان گره‌های واسط جهت کشف مسیرهای همپوشان مشتریان عمل می‌کنند و واحد تحلیل در سطح حساب تجاری پذیرنده است. این چارچوب با ترکیب شبکه‌های عصبی گراف زمانی، انحنای گسسته فرم-ریچی [4, 5] برای مهار پدیده فشردگی اطلاعات [6, 7] و واسنجی زمانی بازه پیش‌بینی یک‌طرفه [8]، امتیاز M-GATO را جهت اولویت‌بندی کمپین استخراج می‌کند. در ادبیات بازاریابی پرداخت، لیو و همکاران (CIKM 2019) [9] از یادگیری بازنمایی گراف جهت بهینه‌سازی مشوق‌های بازاریابی در علی‌پی بهره بردند؛ اما چارچوب آن‌ها در محیط آپالیف‌نظارت‌شده متکی بر لاگ‌های تاریخی کوپن‌های تخفیف و برچسب‌های مداخله عمل می‌کند. در مقابل، سوییچ‌های شاپرکی فاقد داده‌های تاریخی کمپین هستند و HAMTA اولین روش بازاریابی پذیرندگان مبتنی بر گراف نیست، بلکه چارچوبی برای کشف فرصت

خطای برآورد میانگین گردیده و بازه‌های خطای پایداری را نسبت به تقریب پیوسته گوسی فراهم می‌آورد [25].

3. روش پیشنهادی (چارچوب معماری HAMTA)

معماری HAMTA شامل جریان پیوسته‌ای از مراحل پردازش است: ساخت گراف دوبخشی، القای گراف همتایان، پیش‌بینی گراف زمانی، واسنجی نااطمینانی، و محاسبه امتیاز M-GATO (شکل (1)).

شکل (1): معماری چهارمراحل‌ای چارچوب HAMTA در کشف و اولویت‌بندی فرصت تراکنشی پذیرندگان



شکل (1): خط لوله معماری چارچوب HAMTA برای کشف فرصت تراکنشی پذیرندگان

3.1. تعریف مسئله و ساختار داده

دفتر کل تراکنش‌ها به صورت دنباله‌ای از رویدادها

$$L = \{e_1, \dots, e_N\}$$

تعریف می‌شود که در آن هر رویداد شامل پنج فیلد استاندارد است:

$$e_k = \langle \text{pan}_k, \text{amount}_k, \text{merchant_id}_k, \text{create_date}_k, \text{cast_name}_k \rangle$$

شناسه merchant_id بیانگر شناسه پذیرنده ارائه‌شده در دفتر کل PSP است. از همین پنج فیلد پایه و بدون نیاز به متغیرهای خارجی، بردار ویژگی ۶ بُعدی گره پذیرنده به صورت زیر ساخته می‌شود:

$$x_{\{m, t\}} \in \mathbb{R}^{16}$$

مؤلفه‌های این بردار شامل: (۱ تا ۴) وقعه‌های زمانی حجم تراکنش (لگاریتم تراکنش‌های دوره‌های پیشین و میانگین وقعه همسایگان)؛ (۵ تا ۷) شاخص‌های مقیاس مالی استخراج‌شده از مبلغ تراکنش شامل لگاریتم حجم کل، میانگین انحراف معیار مبلغ؛ (۸) وسعت تعاملات مشتریانی یکتا (تعداد کارت‌های متمایز)؛ و (۹ تا ۱۶) بردار واهات نشانگر صنف اقتصادی در میان ۸ صنف تجاری. مسیر وابستگی ویژگی‌ها اکیداً علی است:

$$5 \text{ Raw Ledger Fields} \rightarrow \text{Historical Peer Graph} \rightarrow \text{Peer Lag Aggregation} \rightarrow \text{Temporal GNN (time t)}$$

هدف مسئله در سطح هر پذیرنده $m \in M$ ، پیش‌بینی تعداد تراکنش دوره آتی و تعیین شکاف فرصت ساختاری آن نسبت به بنچ‌مارک محافظه‌کارانه همتایان است:

$$Y_{\{m, t+1\}} \in \mathbb{N}_0, \quad B^{\wedge}G_{\{m, t+1\}}$$

3.2. گراف دوبخشی زمانی کارت-پذیرنده

در هر پنجره زمانی گسترده t ، تراکنش‌ها در قالب گراف دوبخشی زیر سازمان می‌یابند:

$$G^{\wedge}(B)_t = (C_t, M_t, E_t)$$

هر یال دوتایی نشانگر وقوع دست‌کم یک تراکنش توسط کارت c در پایانه m در پنجره t است (یال‌ها باینری هستند تا تمرکز بر ساختار همپلاقاتی توپولوژیک باشد نه حجم تراکنش). کارت‌ها صرفاً به عنوان گره‌های واسط جهت استخراج مسیرهای هم‌پوشان مشتریان عمل می‌کنند و هویت فردی آن‌ها نگهداری نمی‌شود.

3.3. گراف همتایان پذیرنده و تعدیل انحنای

به منظور پرهیز از مقایسه‌های متراکم و پرهزینه $O(|M|^2)$ ، چارچوب HAMTA از ایندکس معکوس کارت به پذیرنده جهت تولید کاندیدها استفاده می‌نماید. نمایه معکوس $I(c)$ تمامی پذیرندگان مشاهده‌شده توسط کارت c در پنجره‌های گذشته را بازی‌یابد و برای هر پذیرنده m ، همسایگی ۲-گامه در زمان $O(|C_m| \cdot d_{\text{card}})$ استخراج می‌شود:

$$C(m) = \bigcup_{c \in C_m} I(c) \setminus \{m\}$$

سپس شباهت پذیرندگان کاندیدا بر اساس رابطه (1) فرمول‌بندی می‌گردد:

$$S(m, j) = \lambda \cdot S_{\text{covisit}}(m, j) + (1 - \lambda) \cdot S_{\text{category}}(m, j) \quad (1)$$

که در آن S_{covisit} شباهت کسب‌وکاری بردار دودویی وقوع مشتریان مشترک و S_{category} تطابق صنف تجاری است. ضریب $\lambda = 0.65$ در پنجره اعتبار‌سنجی گذشته تنظیم شده است. یک هیپ بیشینه همتایان Top-K ($K=6$) را در مرتبه $O(|C(m)| \log K)$ با پیچیدگی کاندیدآبایی محدود به $O(|M| \cdot K \cdot d_{\text{avg}})$ استخراج می‌نماید. از آنجا که رابطه انتخاب Top-K ذاتاً جهت‌دار است، گراف همتایان پیش از محاسبه انحنای با عملکرد اجتماع متقارن‌سازی می‌گردد:

$$G_{\text{peer}} = \text{Top-K} \cup \text{Top-K}^T$$


توجه شود که محاسبه انحنای روی گراف همتایان متقارن‌شده انجام می‌شود. سپس انحنای فرم-رنجی نرمال‌شده افزوده طبق رابطه (2) به عنوان پالایش ساختاری محاسبه می‌شود [4, 5]:

$$F(m, j) = [4 - d(m) - d(j) + 3 \cdot \Delta(m, j)] / \sqrt{[d(m) \cdot d(j)]} \quad (2)$$

که $d(m)$ درجه گره، $\Delta(m, j)$ تعداد مثلث‌های مشترک و مخرج رادیکالی جهت جلوگیری از غلبه گره‌های متراکم مرکزی پیشنهاد شده است. انحنای وزن همتایان را طبق رابطه (3) تعدیل می‌کند:

$$\tilde{w}_{mj} \propto w_{mj} \cdot (1 + \eta \cdot \tanh(F(m, j))) \quad (3)$$

با ضریب مقیاس $\eta = 0.25$ به عنوان تنظیم‌کننده ساختاری و پالایش‌گر روابط همتایان عمل می‌نماید.



شکل (2): تصویرسازی دوبعدی تعبیه‌های گراف همتایان پذیرنده در ۸ صنف تجاری؛ حلقه‌های قرمز نشانگر اهداف افت ساختاری تزیین‌شده هستند.

3.4. پیش‌بینی گراف زمانی با تابع دو جمله‌ای منفی

متغیر هدف، تعداد تراکنش دوره آتی $Y_{m, t+1}$ است. داده‌های تراکنشی بیش‌پراکنندگی شدید نشان می‌دهند ($\text{Var}(Y)/E[Y] \approx 3.24$) که استفاده از توزیع دو جمله‌ای منفی را نسبت به مدل پواسون توصیه می‌کند. لذا مدل بر مبنای معماری توجه گراف زمانی برگرفته از TGAT به تابع درست‌نمایی دو جمله‌ای منفی آموزش می‌یابد:

$$L_{\text{NB}} = - \sum [\ln \Gamma(Y + \phi) - \ln \Gamma(\phi) - \ln \Gamma(Y + 1) + \phi \ln(\phi / (\phi + \hat{\mu})) + Y \ln(\hat{\mu} / (\phi + \hat{\mu}))] \quad (4)$$

که در آن $\hat{\mu}$ میانگین برآوردی و ϕ پارامتر اندازه یا پراکنندگی معکوس (inverse-dispersion/size parameter) است. کلیه ورودی‌ها به اطلاعات تا زمان t محدود بوده و پروتکل آموزش تقدم زمانی مانع از نشت اطلاعات می‌گردد. مدل از معماری TGAT دو لایه با بعد ویژگی ورودی ۱۶، بعد پنهان ۳۲ و ۲ هد توجه بهره می‌برد. آموزش با الگوریتم Adam طی ۷۰ دور با توقف زودهنگام در دوره اعتبار‌سنجی دوره ۳ انجام شده و سپس بر روی داده‌های P_0 تا دوره ۳ نهایی گردیده است.

3.5. واسنجی زمانی بازه پیش‌بینی یک‌طرفه بر روی دوره مستقل

پروتکل زمانی اعتبار‌سنجی شامل تفکیک دقیق دوره‌ها است: دوره‌های ۰ تا ۲ آموزش اولیه، دوره ۳ اعتبار‌سنجی ابرپارامترها، P_0 -دوره ۳ برازش نهایی، دوره ۴ واسنجی کاملاً تمیز بر داده‌های طبیعی دست‌نخورده، و دوره ۵ پنجره آزمون و اعمال افت فرصت. جهت تطبیق دقیق با چولگی و ناهم‌واریانی داده‌های شمارشی با توزیع بیش‌پراکنده، صدک‌های دم یک‌طرفه به صورت نامتقارن برای سقف طبیعی و کف محافظه‌کارانه همتایان واسنجی می‌شوند. پسماندهای یک‌طرفه صعودی نوسانات مثبت طبیعی را می‌سنجند [8]:

$$R_{m^+} = \max(0, Y_m - \hat{\mu}_m)$$

با در نظر گرفتن سطح خطای اسمی $\alpha = 0.15$ (پوشش هدف ۸۵٪ کران بالا)، صدک واسنجی‌شده صعودی استخراج شده و کران بالای طبیعی عملکرد پیش‌بینی مطابق رابطه (5) تعیین می‌شود:

$$q_{\{0.85\}^+} = \text{Quantile}_{\{0.85\}}(\{R_{m^+}\}) \quad (5)$$

چون واسنجی اکیداً بر داده‌های دست‌نخورده دوره ۴ قبل از تزیین افت در دوره ۵ اجرا می‌شود، داده‌های واسنجی به هیچ‌وجه تحت تأثیر افت فرصت مصنوعی قرار ندارند. پوشش یک‌طرفه تجربی ثبت‌شده ($\text{Coverage} = 86.2 \pm 3.1\%$) با عرض بازه میانگین $4/6 \pm 0.3$ تراکنش اعتبار تجربی واسنجی را تایید می‌نماید.

3.6. بنچ‌مارک محافظه‌کارانه همتایان گرافی ($B^{\wedge}G$)

برای جلوگیری از خوش‌بینی مفرط، بنچ‌مارک همتایان بر پایه کران پایین پیش‌بینی همتایان تعریف می‌گردد. به طور متقارن، پسماندهای یک‌طرفه نزولی $\hat{\mu}_j^- = \max\{Y_j - Y_j^+, 0\}$ صدک مستقل دم پایینین $q_{\{0.85\}^-}$ را تعیین نموده و کران پایین محافظه‌کارانه همتا را به دست می‌دهند:

$$L_j^- = \max(0, \hat{\mu}_j^- - q_{\{0.85\}^-})$$

سپس بنچ‌مارک محافظه‌کارانه همتایان مطابق رابطه (6) فرمول‌بندی می‌شود:

$$B^{\wedge}G_{\{m, t+1\}} = [\sum_j \tilde{w}_{mj} \cdot L_{j, t+1}] / [\sum_j \tilde{w}_{mj}] \quad (6)$$

3.7. فرمول امتیاز فرصت M-GATO و تحلیل محاسباتی

شاخص رتبه‌بندی فرصت همتا-محور (M-GATO) حاصل‌ضرب شواهد گرافی در شکاف کران-پیش‌بینی همتایان فرمول‌بندی می‌گردد:

$$Q_{\{m, t\}} = 1 - \exp(-O_{\{m, t\}} / \kappa) \quad (7)$$

در دست‌نمایی NB NLL بر روی مدل‌های دارای خروجی توزیع احتمالی دو جمله‌ای منفی قابل تعریف است و برای مدل‌های نقطه‌ای قطعی درج نگردیده است.

جدول (1): مقایسه دقت پیش‌بینی تعداد ترانکشن دوره‌های آتی بر روی پنجره آزمون (۱۰ سید تصادفی)

مدل / معیار	MAE	RMSE	sMAPE	NB NLL
Naive Persistence (ماندگاری)	۰/۲۰ ± ۰/۴۶۱	۰/۲۷ ± ۰/۵۷۸	۱/۴۹ ± ۲۲/۴۰	—
Moving Average (میانگین متحرک)	۰/۱۹ ± ۰/۳۵۱	۰/۲۸ ± ۰/۴۵۸	۱/۰۳ ± ۲۶/۰۵	—
Exp. Smoothing (هموارسازی نمایی)	۰/۱۶ ± ۰/۲۴۱	۰/۲۸ ± ۰/۴۴۶	۰/۹۲ ± ۲۵/۴۲	—
Tabular GBDT (جدولی RFM)	۰/۱۲ ± ۰/۲۸۹	۰/۴۲ ± ۰/۵۳۱	۰/۷۹ ± ۲۷/۶۸	—
NB-GLM (انرژی صنف)	۰/۲۰ ± ۰/۳۷۸	۰/۳۸ ± ۰/۴۹۶	۱/۰۶ ± ۲۷/۵۵	۰/۰۲ ± ۳/۱۷
Static GNN (گراف ایستا)	۰/۵۴ ± ۰/۹۸۸	۰/۷۷ ± ۰/۷۵۶	۲/۱۳ ± ۳۸/۴۷	۰/۰۳ ± ۳/۳۱
HAMTA Temporal (پیشنهادی)	۰/۴۲ ± ۰/۴۶۸	۰/۵۸ ± ۰/۵۸۶	۲/۱۱ ± ۳۱/۳۷	۰/۳۱ ± ۳/۵۱


مدل پیشنهادی HAMTA به خطای MAE معادل ۰/۴۲ ± ۰/۴۶۸ دست یافته و عملکرد بهتری نسبت به گراف ایستا (۰/۵۴ ± ۰/۹۸۸) ثبت کرده است. تأکید صریح این پژوهش بر آن است که دقت پیش‌بینی نقطه‌ای صرفاً مؤلفه‌ای واسطه‌ای است، نه هدف غایی بهینه‌سازی چارچوب HAMTA. مدل‌های آماری تک‌متغیره گرچه خطای نقطه‌ای اندکی کمتر دارند، نسبت به ساختار شبکه تعاملی و همپوشانی مشتریان کاملاً نابینا بوده و قادر به استخراج پنج‌مارک هم‌تایان نیستند. HAMTA افت اندک در خطای پیش‌بینی نقطه‌ای را در ازای یادگیری بازنمایی‌های پیوندی پویا و امکان‌پذیر ساختن رتبه‌بندی ساختاری فرصت‌ها می‌پذیرد.

5.2. اولویت‌بندی کمپین‌های بازاریابی

جدول (2) کارایی استراتژی‌ها را در رتبه‌بندی ۳۵ پذیرنده دارای بالاترین اولویت کمپین (۱۰٪ سبد کل) طی ۱۰ سید تصادفی گزارش می‌نماید.

جدول (2): پنج‌مارک رتبه‌بندی و اولویت‌بندی پذیرندگان کاندیدای کمپین (Top-35، میانگین ۱۰ سید)

استراتژی رتبه‌بندی	P@35	R@35	R-Prec	NDCG@35	MAP@35
کمترین حجم	۰/۵۳ ± ۰/۱۹۷	۰/۵۳ ± ۰/۱۳۳	۰/۵۲ ± ۰/۱۹۴	۰/۵۳ ± ۰/۲۰۳	۰/۲۰ ± ۰/۰۵۹
حجم دوره پیشین	۰/۵۳ ± ۰/۲۰۰	۰/۵۳ ± ۰/۱۴۸	۰/۵۲ ± ۰/۲۰۲	۰/۵۳ ± ۰/۲۴۵	۰/۲۳ ± ۰/۰۸۲
شکاف جدولی GBDT	۰/۶۴ ± ۰/۲۱۴	۰/۶۳ ± ۰/۱۴۴	۰/۵۲ ± ۰/۱۸۸	۰/۵۳ ± ۰/۲۳۷	۰/۲۳ ± ۰/۰۸۲
شکاف هم‌تایان kNN	۰/۵۳ ± ۰/۲۳۱	۰/۵۳ ± ۰/۱۵۶	۰/۵۲ ± ۰/۲۲۱	۰/۵۳ ± ۰/۲۴۱	۰/۲۳ ± ۰/۰۸۰
شکاف گراف ایستا	۰/۵۳ ± ۰/۲۸۴	۰/۵۳ ± ۰/۱۹۲	۰/۵۳ ± ۰/۲۸۷	۰/۵۳ ± ۰/۲۴۷	۰/۲۳ ± ۰/۰۵۵
مرز تصادفی SFA	۰/۵۳ ± ۰/۳۵۷	۰/۵۳ ± ۰/۲۴۰	۰/۵۳ ± ۰/۲۳۳	۰/۵۳ ± ۰/۲۸۳	۰/۲۳ ± ۰/۱۷۱
M-GATO (Q بنون)	۰/۵۳ ± ۰/۳۷۲	۰/۵۳ ± ۰/۲۵۲	۰/۵۳ ± ۰/۳۴۲	۰/۵۳ ± ۰/۳۹۶	۰/۲۳ ± ۰/۰۸۳
پیشنهادی HAMTA	۰/۵۳ ± ۰/۳۶۶	۰/۵۳ ± ۰/۲۴۶	۰/۵۳ ± ۰/۳۴۲	۰/۵۳ ± ۰/۳۸۲	۰/۲۳ ± ۰/۰۸۰



شکل (4): مقایسه کمی مدل‌ها در (الف) دقت پیش‌بینی و (ب) کیفیت اولویت‌بندی کمپین در ۱۰ سید تصادفی

با توجه به شیوع فرصت‌های واقعی در سطح ۵۲ پذیرنده از ۳۵۰ پذیرنده (شانس تصادفی کل سید معادل ۰/۱۴۸۶ یا ۱/۴۹٪، و شانس تصادفی جامعه کاندیداهای معادل ۰/۱۷۴٪)، نتایج جدول (2) نشان می‌دهد که مدل پیشنهادی HAMTA با $Precision@35$ معادل ۰/۳۶۶ ± ۰/۱۲۰، $Recall@35$ معادل ۰/۲۴۶ ± ۰/۰۸۱ (با سقف نظری ۰/۶۷۳ برای ۳۵ جایگاه از ۵۲ هدف: $۵۲/۳۵ = ۰/۶۷۳$)، $NDCG@35$ معادل ۰/۳۸۲ ± ۰/۱۱۶ و $R-Precision$ معادل ۰/۳۴۲ ± ۰/۰۷۷، به ضریب برتری ۲/۴۶ برابری نسبت به انتخاب تصادفی کل سید (و ۲/۱۰ برابری نسبت به خط‌بنای تصادفی درون‌جامعه کاندیداهای) دست می‌یابد.

5.3. ارزیابی چندبوجه‌ای و آزمون معناداری آماری

جدول (3) کارایی مدل را در سقف‌های مختلف بودجه کمپین $K \in \{10, 20, 35, 50\}$ گزارش می‌نماید.

جدول (3): مقایسه کارایی اولویت‌بندی در بودجه‌های مختلف و آزمون‌های آماری (۱۰ سید تصادفی)

بودجه	استراتژی اولویت‌بندی	Prec@K	Recall@K	NDCG@K
۱۰	کمترین حجم	۰/۱۰ ± ۰/۲۱۰	۰/۲۰ ± ۰/۴۰	۰/۲۱ ± ۰/۴۵
۱۰	شکاف جدولی GBDT	۰/۲۰ ± ۰/۲۷۰	۰/۲۲ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۱۰	شکاف گراف ایستا	۰/۲۰ ± ۰/۲۷۰	۰/۲۱ ± ۰/۵۱	۰/۲۷ ± ۰/۸۲
۱۰	مرز تصادفی SFA	۰/۲۰ ± ۰/۲۴۰	۰/۲۲ ± ۰/۵۳	۰/۲۷ ± ۰/۸۳
۱۰	مدل پیشنهادی HAMTA	۰/۲۰ ± ۰/۲۷۰	۰/۲۲ ± ۰/۵۳	۰/۲۷ ± ۰/۸۳
۲۰	کمترین حجم	۰/۲۰ ± ۰/۲۷۰	۰/۲۲ ± ۰/۵۳	۰/۲۷ ± ۰/۸۳
۲۰	شکاف جدولی GBDT	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۲۰	شکاف گراف ایستا	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۲۰	مرز تصادفی SFA	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۲۰	مدل پیشنهادی HAMTA	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۳۵	کمترین حجم	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۳۵	شکاف جدولی GBDT	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۳۵	شکاف گراف ایستا	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۳۵	مرز تصادفی SFA	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۳۵	مدل پیشنهادی HAMTA	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۵۰	کمترین حجم	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۵۰	شکاف جدولی GBDT	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳
۵۰	شکاف گراف ایستا	۰/۲۵ ± ۰/۲۴۵	۰/۲۸ ± ۰/۵۲	۰/۲۸ ± ۰/۸۳


$$M-GATO \{m, t\} = Q \{m, t\} \cdot [(B^*G_{-} \{m, t+1\} - U_{-} \{m, t+1\}) / (B^*G_{-} \{m, t+1\} + \epsilon)] +$$

که در آن $O_{m, t} = \max(0, x)$ ، $\kappa = 18$ پارامتر اشتباع شواهد است. میانگین Top-K کران-پیش‌بینی هم‌تایان (Forecast-Bound Peer Gap) معادل $B^*G - U$ است، نه صرفاً افت لحظه‌ای مشاهده‌شده کنونی ($B^*G - Y$). ترانکشن واقعی Y مستقیماً در صورت کسر قرار ندارد؛ چرا که پیش‌بینی نقطه‌ای $\hat{y}$ و کران بالای کالیبره‌شده U از پیش بر سوابق تاریخی شرطی شده‌اند. کسر مستقیم Y موجب اختلاط نوسانات کوتاه‌مدت با فرصت ساختاری پایدار می‌گردد. ضریب $Q_{m, t}$ به عنوان جریمه کاهش انقباضی برای پذیرندگان منفرد عمل می‌کند.

مثال عددی: پذیرنده 00322 MERCH در صنف مسافرتی را در نظر بگیرید: عملکرد فعلی $Y = 100$ ، پیش‌بینی مدل $\hat{y} = 105.0$ و کران بالای کالیبره‌شده $U = 112.0$ ترانکشن است. هم‌تایان این پذیرنده به پنج‌مارک محافظه‌کارانه $B^*G = 170.0$ دست یافته‌اند و ضریب اتکای گرافی $Q = 0.90$ است. بنابراین شکاف کران-پیش‌بینی هم‌تایان و امتیاز M-GATO به صورت زیر محاسبه می‌شوند:

$$B^*G - U = 170.0 - 112.0 = 58.0 \quad (\text{Relative Gap} = 0.3412) \\ M-GATO = 0.3412 \times 0.90 = 0.307$$

تفسیر دقیق: این پذیرنده واجد ۵۸ ترانکشن شکاف کران-پیش‌بینی نسبت به سقف طبیعی خود تا پنج‌مارک هم‌تایان است (در حالی که تفاوت با عملکرد فعلی ۷۰ ترانکشن است).



شکل (3): مقایسه مؤلفه‌های شاخص M-GATO: ترانکشن مشاهده‌شده، پیش‌بینی مدل، کران بالای طبیعی و پنج‌مارک هم‌تایان

4. طراحی تجربی و پیکربندی داده‌ها

داده‌های ارزیابی شامل جریان شبیه‌سازی‌شده طی ۱۰ سید تصادفی با ۳۵۰۰۰ ترانکشن، ۳۵۰ پذیرنده و ۱۴۸۰ کارت در ۸ صنف اقتصادی طی ۹۰ روز است. اصناف تجاری پیرو توزیع متوازن هستند: سوپرمارکت (۲۵٪)، رستوران (۱۸٪)، پوشاک (۱۵٪)، لوازم الکترونیکی (۱۰٪)، پزشکی (۱۰٪)، گردشگری (۵٪)، طلا (۴٪) و صنعتی (۳٪). پروتکل زمانی شامل ۶ دوره ۵ روزه است: آموزش دوره‌های ۱ تا ۲، اعتبارسنجی دوره ۳، و اسنچی کاملاً تمیز دوره ۴، و آزمون ارزیابی دوره ۵. هیچ داده آزمونی وارد فرایند آموزش و اسنچی نشده است.


فرمول‌بندی برچسب فرصت: برچسب فرصت منحصرأ به صورت بازاریابی ریاضی اهداف افت ساختاری مصنوعی تعریف می‌شود. یک پذیرنده دارای برچسب فرصت $(1 = Opportunity(m))$ است اگر و تنها اگر افت ساختاری برون‌زای $d > 0$ در نرخ تولید ترانکشن آن از دوره پیش ۴ آغاز شده و در دوره آزمون ۵ تداوم یافته باشد. دقیقاً تعداد ۵۲ پذیرنده از ۳۵۰ پذیرنده (۱۴/۹٪) با نمونه‌گیری طبقه‌بندی‌شده از میان کاندیداهای دارای پنج‌مارک فعال هم‌تایان (میانگین ۲۹۹ پذیرنده در ۱۰ سید با شانس تصادفی درون‌جامعه‌ای ۱۷/۴٪) در تمامی اصناف به عنوان هدف تعیین شدند. همپوشانی هدف-همتا پایین بوده و به طور میانگین تنها ۱۱/۸٪ از هم‌تایان یک هدف، خودشان هدف هستند. سناریوها شامل الف (افت ۱۸٪ با نويز ۳/۰)، ب (افت ۳۲٪ با نويز ۱/۸) و ج (افت ۴۸٪ با نويز ۰/۹) هستند. در سناریوی شاهد منفی (Scenario 0)، مقدار افت برای تمامی پذیرندگان صفر بوده تا وضعیت عدم وجود مثبت واقعی ($TP = 0$) جهت ارزیابی نرخ هشدار کاذب بررسی شود.

تنظیم ابرپارامترها: مقادیر بهینه در پنجره تاریخی P0-دوره ۳ تنظیم گردیدند: ضریب شباهت $\eta = 0.65$ ، ضریب انحنا $\eta = 0.25$ ، اشتباع گرافی $\kappa = 18.0$ ، تعداد همسایگان $K = 6$ و خطای اسنچی $\alpha = 0.15$. تحلیل حساسیت تجربی در ۱۰ سید نشان داد کیفیت رتبه‌بندی در برابر تغییرات همسایگی $K \in [3, 10]$ (دامنه NDCG بین ۰/۳۵۳ تا ۰/۳۹۷)، وزن انحنا $\eta \in [0.0, 0.5]$ (دامنه NDCG بین ۰/۳۸۲ تا ۰/۴۰۹) و پارامتر اشتباع $\kappa \in [10, 30]$ (دامنه NDCG بین ۰/۳۸۲ تا ۰/۳۹۷) پایداری مناسبی دارد.

5. نتایج و تحلیل تجربی

5.1. ارزیابی دقت پیش‌بینی طبیعی ترانکشن‌ها

جدول (1) نتایج پیش‌بینی تعداد ترانکشن‌ها را در پنجره آزمون دست‌نخورده (بدون تداخل با افت‌های مصنوعی) طی ۱۰ سید تصادفی گزارش می‌کند. معیار



شکل (5): دقت بازیافت فرصت (Precision@K) در سقف‌های مختلف بودجه کمپین بازاریابی

تحلیل فروش پذیرندگان خرد (Micro-Merchant Bias): به دلیل مخرج کوچک در پذیرندگان کم‌ترانکس، شاخص M-GATO در حالت خام به پذیرندگان خرد حساس است (۵۶/۰ ± ۱۶/۵٪ کاندیداهای زیر ۱۰ ترانکس). بررسی حساسیت نشان می‌دهد اعمال آستانه‌های ترانکس $Y \geq 5$ و 10، سهم کاندیداهای خرد را به ترتیب به ۳۴/۱٪، ۱۸/۲٪ و ۴/۳٪ کاهش می‌دهد. اعمال فیلتر ۱۰ ترانکس دقت را در سطح 0.286 ± 0.056 و NDCG را در 0.227 ± 0.077 تثبیت می‌نماید. همچنین ضریب پیوسته اتکالی فعالیت با $\tau_a = 15$ به عنوان نسخه عملیاتی توصیه شده (به جای فیلتر آستانه‌ای سخت)، نوسانات پذیرندگان بسیار خرد را مهار می‌سازد:

$$Q_{total} = Q_{graph} \cdot (1 - \exp(-Y_m / \tau_a))$$

تهدیدات اعتبار تجربی: (۱) سلامت پروتکل ارزیابی و تمایز پروتکل‌ها: چارچوب HAMTA بر مبنای «پروتکل الف: بازیابی و اولویت‌بندی افت ساختاری مستمر» (Persistent Underperformance Recovery) عمل می‌کند که در آن واگرایی نزولی در دوره پیش (دوره ۴) آشکار شده و در پنجره تصمیم‌گیری کمپین (دوره ۵) استمرار می‌یابد. طراحی پروتکل مانع از دسترسی به اطلاعات دوره از من ۵ در زمان پیش‌بینی و رتبه‌بندی می‌شود. در نقطه مقابل، در «پروتکل ب: پیش‌بینی شوک‌های ناگهانی پیش‌بینی» (Pure Ex-Ante Shocks) که افت به صورت تصادفی صرفاً در دوره ۵ بدون هیچ نشانه قبلی رخ دهد، هیچ مدلی بدون ویژگی‌های پیش‌نگر قادر به تشخیص برتر از شانس تصادفی (۱۴/۶٪) نخواهد بود. (۲) اثر همنوع‌خواری تجاری (Peer Cannibalization): چارچوب استقلال تقاضای پذیرندگان را فرض می‌کند و رقابت محلی پایانه‌های همسایه به صورت مستقیم لحاظ نشده است. (۳) متغیرهای مشاهده‌نشده: داده‌ها محدود به ۵ فیلد پایه دفتر کل بوده و اطلاعاتی نظیر مساحت فروشگاه، تعداد پرسنل و ساعات کاری در دسترس نیست. (۴) محیط شبیه‌سازی: شاخص M-GATO اولویت‌بندی بر اساس افت‌های ساختاری تزیق شده است؛ اعتبارسنجی نهایی نیازمند آزمون‌های تصادفی A/B در کمپین‌های بازاریابی آتی بانک است.

پیچیدگی محاسباتی: اندازه‌گیری زمان اجرا در محیط سخت‌افزاری استاندارد (پردازنده Intel Core i7، ۱۶ گیگابایت رم، PyTorch 2.4) رشد تجربی تقریباً خطی در پیچیدگی‌های ارزیابی‌شده را نشان داد: مقیاس کوچک (۱۰۰ پذیرنده: ۱/۵۴ ثانیه، ۶۵۰۵ ترانکس/ثانیه)؛ مقیاس متوسط (۳۵۰ پذیرنده: ۶/۲۸ ثانیه، ۵۵۷۰ ترانکس/ثانیه)؛ و مقیاس بزرگ (۱۰۰۰ پذیرنده: مجموعاً ۲۸/۱۷ ثانیه، ۳۵۵۰ ترانکس/ثانیه). کاندیدایی با اندیس معکوس کارت‌ها پیچیدگی را به $O(|M| \cdot K \cdot d_{avg})$ محدود نموده و مقیاس‌پذیری عملیاتی روش را تأیید می‌کند.

6. نتیجه‌گیری و کارهای آینده

در این مقاله چارچوب هوش مصنوعی گراف زمانی HAMTA در قالب یک ساختار تصمیم‌گیری سه‌لایه برای اولویت‌بندی فرصت‌های بدون برچسب مداخله (Treatment-label-free) پذیرندگان ارائه گردید. HAMTA با بازتعریف روابط ترانکسی به صورت گراف دوبخشی، به‌رمگیری از انحنا فرم‌ریجی به عنوان پالایش ساختاری، پیش‌بینی تعداد ترانکس با دوجمله‌ای منفی و استخراج کران بالای طبیعی با واسنجی بازه پیش‌بینی زمانی، شاخص M-GATO را برای تفکیک پذیرندگان دارای پتانسیل ساختاری از نوسانات تصادفی بدون نیاز به برچسب‌های مداخله تاریخی ارائه داد. نتایج آزمایش‌ها بر روی ۱۰ سید تصادفی، بازیابی سیگنال افت ساختاری را اعتبارسنجی نموده و بهبود معنادار آماری در مقایسه‌های کلیدی را پس از تصحیح هلم-بونفرونی به اثبات رساندند. چشم‌انداز آینده: در فازهای بعدی، تلفیق امتیاز اولویت‌بندی M-GATO با مدل‌های برآورد اثر علی (ITE Uplift Modeling) پس از اجرای آزمایشی کمپین در شبکه بانکی پیگیری خواهد شد. بیانیه دسترسی به کد و محرمانگی داده‌ها: پیاده‌سازی کامل چارچوب و کدهای تولید داده‌های شبیه‌سازی پس از انتشار مقاله در مخزن گیت‌هاب در دسترس قرار خواهد گرفت. داده‌های شبیه‌سازی با سیدهای ثبت‌شده کاملاً قابل بازتولید هستند؛ اما انتشار داده‌های واقعی سوییچ‌های شاپرکی به دلیل الزامات محرمانگی و استاندارد PCI-DSS امکان‌پذیر نمی‌باشد.

مراجع

- [1] Bank for International Settlements (BIS), "Red Book: Statistics on payment, clearing and settlement systems", CPMI, Basel, Switzerland, Tech. Rep., 2023.
- [2] European Central Bank (ECB), "Study on payment attitudes of consumers in the euro area (SPACE)", ECB, Frankfurt, Germany, Tech. Rep., Dec. 2022.

۵۰	مرز تصادفی SFA	0.222 ± 0.079	0.310 ± 0.076	0.322 ± 0.081
۵۰	مدل پیشنهادی HAMTA	0.320 ± 0.072	0.327 ± 0.069	0.340 ± 0.080

تحلیل بودجه‌های چندگانه و معناداری آماری: در سقف بسیار محدود $K = 10$ ، مدل مرز تصادفی SFA به دقت بالاتری (0.430 ± 0.127) نسبت به HAMTA (0.400 ± 0.089) دست می‌یابد؛ اما با افزایش ظرفیت کمپین، HAMTA رقابت‌پذیری بیشتری نشان داده و از بودجه $K = 20$ به بعد بر ختمینای مرزی SFA غلبه می‌کند: در بودجه $K = 20$ دقت ۰/۴۱۰ در برابر ۰/۳۴۵؛ در $K = 35$ دقت ۰/۳۶۶ در برابر ۰/۳۵۷؛ و در $K = 50$ دقت ۰/۳۴۰ در برابر ۰/۳۲۲. تحت تصحیح هلم-بونفرونی برای مقایسه‌های چندگانه، برتری‌های HAMTA نسبت به ختمینای سنتی کمترین حجم و مدل جدولی در تمامی بودجه‌ها کاملاً معنادار باقی می‌ماند ($p_{adj} < 0.05$): در بودجه $K = 10$ نسبت به کمترین حجم ($p_{adj} = 0.0156$) و مدل جدولی ($p_{adj} = 0.0293$)؛ در بودجه $K = 20$ نسبت به کمترین حجم ($p_{adj} = 0.0156$) و مدل جدولی ($p_{adj} = 0.0176$)؛ و در $K = 35$ نسبت به کمترین حجم ($p_{adj} = 0.0176$) و مدل جدولی ($p_{adj} = 0.0078$). نسبت به گراف ایستا در $K = 35$ ، آزمون خام ویلکسون معنادار است ($p = 0.0488$) که پس از تصحیح هلم-بونفرونی به $p_{adj} = 0.0977$ تعدیل می‌شود. تفاوت‌های HAMTA با ختمینای SFA به سطح معناداری آماری نمی‌رسد و SFA به عنوان یک پنج‌مارک مرزی ناپارامتریک قدرتمند عمل نمی‌نماید.

5.4. ارزیابی استحکام و تحلیل عدم دورباطل در سناریوها

جدول (4) عملکرد مدل را در چهار سناریوی مستقل با شدت‌های مختلف افت و نویز نشان می‌دهد.

جدول (4): ارزیابی چندسناریویی چارچوب و نرخ هشدار کاذب (۱۰ سید تصادفی)

سناریوی ارزیابی	افت	Prec@35	NDCG@35	Weak-Support %	پوشش
شاهد منفی	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۳۱ ± ۰/۰۶۲
سناریو الف (ضعیف)	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۴۴ ± ۰/۰۱۹
سناریو ب (متوسط)	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۳۹ ± ۰/۰۰۷
سناریو ج (قوی)	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۰۰ ± ۰/۰۰۰	۰/۰۴۱ ± ۰/۰۰۳

در سناریوی شاهد منفی (سناریو ۰)، مدل طبق ساختار اولیه هیچ مثبت واقعی تولید نمی‌کند ($TP = 0$)؛ نرخ انتخاب ۰/۱۰۰ گزارش شده مستقیماً ناشی از سهم بودجه انتخاب ثابت ۳۵ پذیرنده برتر از کل ۳۵۰ پذیرنده ($35/350 = 0.1$) است و نباید به عنوان تضمین اختصاصی کنترل خطای مثبت کاذب مدل تفسیر گردد. در عوض، پوشش تجربی بازه پیش‌بینی ($86/2 \pm 2/1$ ٪) با عرض بازه میانگین $4/6 \pm 0/3$ ترانکس) به عنوان شاخص مستقل تأیید می‌نماید که کران‌های واسنجی‌شده به خوبی نوسانات طبیعی را در بر گرفته و مانع از تولید شکاف‌های فرصت غیر واقعی می‌گردد.

5.5. مطالعه تفکیکی حذف مؤلفه‌ها (Ablation Study)

جدول (5) سهم تفکیکی هر یک از اجزای معماری را در مقایسه با مدل کامل همراه با آزمون معناداری آماری نشان می‌دهد.

جدول (5): نتایج مطالعه حذف مؤلفه‌ها و آزمون معناداری آماری ویلکسون (۱۰ سید تصادفی)

ترکیب معماری	NDCG@35	Prec@35	A NDCG	معماری آماری
مدل کامل پیشنهادی HAMTA	۰/۳۸۲	۰/۳۶۶	—	مبتدا (پیشنهادهای)
بدون الحاقی فرم‌ریجی	۰/۲۸۴	۰/۳۴۹	۰/۰۰۲	$p = 0.846$
بدون شواهد گراف (Q=1)	۰/۲۹۶	۰/۳۷۴	۰/۰۱۲	$p = 0.375$
بدون کران نااطمینانی	۰/۳۱۵	۰/۳۷۴	۰/۰۱۲	$p = 0.027$
بدون پنج‌مارک گراف	۰/۳۹۴	۰/۳۵۴	۰/۰۱۲	$p = 0.695$
بدون پویایی زمانی	۰/۳۱۰	۰/۳۸۶	۰/۰۱۲	$p = 0.084$
بدون ساختار گراف (جدولی)	۰/۲۲۷	۰/۲۱۴	۰/۰۲۵	$p = 0.002$

تحلیل مطالعه تفکیکی و معماری سه‌لایه: معماری HAMTA تفکیک صریحی میان موتور کارایی رتبه‌بندی، سیرهای حفاظتی ریسک و پالایش ساختاری قائل است: (۱) موتور رتبه‌بندی رابطه‌ای: بازنمایی گراف دوبخشی زمانی عامل اصلی ارتقای رتبه‌بندی است؛ افزودن ساختار گراف در برابر مدل جدولی GBDT، شاخص $NDCG@35$ را به میزان 0.145 ± 0.023 (از 0.237 به 0.382 ، $p = 0.0020$) و پویایی‌های زمانی شاخص را به میزان 0.0840 ± 0.0020 (از 0.0840 به 0.0840) ارتقا می‌دهد. (۲) سیرهای حفاظتی عملیاتی: کران نااطمینانی یکطرفه U و ضریب شواهد گراف Q برای پیشینه‌سازی رتبه‌بندی خام طراحی نشده‌اند، بلکه نقش فیلتر محافظه‌کارانه تجاری دارند. حذف U اگرچه ظاهراً NDCG خام را به 0.415 ± 0.0273 می‌رساند، اما نرخ هشدارهای کاذب را در نوسانات طبیعی به شدت بالا می‌برد زیرا واریانس مثبت طبیعی پیش‌بینی را به عنوان فرصت قلمداد می‌کند. همچنین حذف Q موجب افزایش نرخ انتخاب پذیرندگان کم‌پشتیبان به $24/3$ ٪ می‌گردد. (۳) پالایش ساختاری: انحنا فرم-ریجی نقش تنظیم‌کننده ساختاری ضد گلوگاه را ایفا نموده و اثر تفکیکی مستقیمی بر شاخص رتبه‌بندی ندارد ($\Delta = 0.002$ ، $p = 0.8457$).

5.6. مطالعه موردی و مهار ارباب پایانه‌های خرد

جدول (6) مشخصات نمونه‌ای از پذیرندگان منتخب را بر روی داده‌های شبیه‌سازی‌شده نشان می‌دهد.

جدول (6): مشخصات پذیرندگان نمونه منتخب با بالاترین اولویت کمپین

شناسه	صفت تجاری	واقعی	پیش‌بینی	کران بالا	پنج‌مارک	امتیاز
۰۰۱۴۱MERCH	مصالح صنعتی	۲۸	۳۱/۱	۳۷/۱	۵۶/۴	۰/۳۰۱
۰۰۲۴۷MERCH	مسافرتی	۸	۸/۵	۱۴/۵	۲۱/۳	۰/۲۶۲
۰۰۲۲۲MERCH	مسافرتی	۱۰۰	۱۰۵/۰	۱۱۲/۰	۱۷/۰	۰/۳۰۷
۰۰۲۰۷MERCH	مصالح صنعتی	۳۰	۳۲/۸	۳۸/۸	۵۴/۷	۰/۲۲۷
۰۰۲۰۶MERCH	پزشکی	۷	۹/۵	۱۵/۵	۲۱/۸	۰/۲۲۸

- [3] J. T. Wei, S. Y. Lin, H. H. Wu, "A review of the application of RFM model", *African Journal of Business Management*, Vol. 4, No. 19, pp. 4199-4206, 2010.
- [4] R. Forman, "Bochner's method for cell complexes and combinatorial Ricci curvature", *Discrete and Computational Geometry*, Vol. 29, No. 3, pp. 323-374, 2003.
- [5] M. Weber, E. Saucan, J. Jost, "Characterizing complex networks with Forman-Ricci curvature", *Journal of Complex Networks*, Vol. 5, No. 4, pp. 527-550, 2017.
- [6] J. Topping, F. Di Giovanni, B. P. Chamberlain, X. Dong, M. M. Bronstein, "Understanding over-squashing and bottlenecks via curvature", *Proc. 10th Int. Conf. on Learning Representations (ICLR)*, 2022.
- [7] I. Marisca, J. Bamberger, C. Alippi, M. M. Bronstein, "Over-squashing in spatiotemporal graph neural networks", *Advances in Neural Information Processing Systems (NeurIPS 38)*, Vol. 38, pp. 38213-38243, 2024.
- [8] A. N. Angelopoulos, S. Bates, "A gentle introduction to conformal prediction and distribution-free uncertainty", *arXiv preprint arXiv:2107.07511*, 2021.
- [9] Z. Liu, D. Wang, Q. Yu, Z. Zhang, Y. Shen, J. Ma, W. Zhong, J. Gu, J. Zhou, S. Yang, Y. Qi, "Graph representation learning for merchant incentive optimization in mobile payment marketing", *Proc. 28th ACM Int. Conf. on Information and Knowledge Management (CIKM)*, pp. 2577-2584, 2019.
- [10] M. Weber et al., "Anti-money laundering in Bitcoin: Experimenting with graph convolutional networks", *Proc. KDD Workshop on Anomaly Detection in Finance*, 2019.
- [11] Y. Dou, Z. Liu, L. Sun, Y. Deng, H. Peng, P. S. Yu, "Enhancing graph neural network-based fraud detectors against camouflaged fraudsters", *Proc. 29th ACM Int. Conf. on Information and Knowledge Management (CIKM)*, pp. 315-324, 2020.
- [12] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio, "Graph attention networks", *Proc. 6th Int. Conf. on Learning Representations (ICLR)*, 2018.
- [13] W. L. Hamilton, R. Ying, J. Leskovec, "Inductive representation learning on large graphs", *Advances in Neural Information Processing Systems (NeurIPS 30)*, pp. 1024-1034, 2017.
- [14] T. N. Kipf, M. Welling, "Variational graph auto-encoders", *NIPS Workshop on Bayesian Deep Learning*, 2016.
- [15] M. Tare, C. Rattasits, Y. Wu, E. Wielewski, "Harnessing GraphSAGE for learning representations of massive transactional networks", *Graph-Based Representations in Pattern Recognition (GbrPR)*, *Lecture Notes in Computer Science*, Vol. 14782, pp. 179-188, Springer, 2025.
- [16] D. Xu, C. Ruan, E. Korpeoglu, S. Kumar, K. Achan, "Inductive representation learning on temporal graphs", *Proc. 8th Int. Conf. on Learning Representations (ICLR)*, 2020.
- [17] E. Rossi, B. Chamberlain, F. Frasca, D. Eynard, F. Monti, M. Bronstein, "Temporal graph networks on dynamic graphs", *ICML Workshop on Graph Representation Learning*, 2020.
- [18] A. Pareja et al., "EvolveGCN: Evolving graph convolutional networks for dynamic graphs", *Proc. 34th AAAI Conf. on Artificial Intelligence*, pp. 5363-5370, 2020.
- [19] Y. Zheng, L. Yi, Z. Wei, "A survey of dynamic graph neural networks", *Frontiers of Computer Science*, Vol. 19, No. 6, Art. 196323, 2025.
- [20] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam, P. Vandergheynst, "Geometric deep learning: Going beyond Euclidean data", *IEEE Signal Processing Magazine*, Vol. 34, No. 4, pp. 18-42, 2017.
- [21] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, E. Lefebvre, "Fast unfolding of communities in large networks", *Journal of Statistical Mechanics: Theory and Experiment*, 2008.
- [22] F. Di Giovanni, J. Rowbottom, B. P. Chamberlain, T. Markovich, M. M. Bronstein, "Graph neural networks as gradient flows: understanding over-smoothing and over-squashing via total variation", *Proc. 11th Int. Conf. on Learning Representations (ICLR)*, 2023.
- [23] T. Wang, J. Kang, Y. Yan, A. Kulkarni, D. Zhou, "Non-exchangeable conformal prediction for temporal graph neural networks", *Proc. 31st ACM SIGKDD Conf. on Knowledge Discovery and Data Mining (KDD)*, Vol. 2, pp. 3031-3042, 2025.
- [24] S. C. Kumbhakar, C. A. K. Lovell, "Stochastic Frontier Analysis", *Cambridge University Press*, Cambridge, U.K., 2000.
- [25] A. C. Cameron, P. K. Trivedi, "Regression Analysis of Count Data", 2nd ed., *Cambridge University Press*, Cambridge, U.K., 2013.
- [26] E. Ascarza, "Retention first, but for whom? Identifying targets for churn management", *Journal of Marketing Research*, Vol. 55, No. 2, pp. 181-198, 2018.
- [27] F. Devriendt, D. Moldovan, W. Verbeke, "Why you should stop using cross-entropy for uplift modeling", *Information Sciences*, Vol. 535, pp. 110-126, 2020.