

از داده تراکنشی تا هوشمندی سازمانی: ارائه چارچوب معماری مبتنی بر گراف برای کشف مشتری در صنعت پرداخت

نام و نام خانوادگی نویسنده اول^۱، نام و نام خانوادگی نویسنده دوم^۲، نام و نام خانوادگی نویسنده سوم^۳

^۱ رتبه علمی نویسنده، گروه آموزشی یا واحد سازمانی مربوطه، نام سازمان، شهر
آدرس پست الکترونیکی (* نویسنده مسئول)

^۲ رتبه علمی نویسنده، گروه آموزشی یا واحد سازمانی مربوطه، نام سازمان، شهر
آدرس پست الکترونیکی

^۳ رتبه علمی نویسنده، گروه آموزشی یا واحد سازمانی مربوطه، نام سازمان، شهر
آدرس پست الکترونیکی

چکیده

تحلیل رفتار مشتریان در شبکه پرداخت الکترونیک اغلب بر شاخص‌های خلاصه‌شده جدولی نظیر تازگی، تکرار و ارزش مالی استوار است و ساختار تعاملی میان ابزارهای پرداخت، پایانه‌های پذیرندگی و اصناف تجاری را به صورت مستقیم لحاظ نمی‌کند. در این مقاله، چارچوبی مبتنی بر خودرمزگذار شبکه عصبی توجه‌محور به همراه انحنای گسسته فرم-ریچی روی ابرگراف دوبخشی کارت-پذیرنده (HG-CAN) جهت استخراج بازنمایی رفتار تراکنشی و بخش‌بندی کارت‌های پرداخت بررسی می‌شود. در این الگو، تراکنش‌ها به صورت یک ابرگراف دوبخشی مدل‌سازی شده و انحنای فرم-ریچی بر روی یال‌های شبکه تصویرشده جهت تعدیل وزن‌های مکانیزم توجه گراف محاسبه می‌گردد تا پیوندهای گلوگاهی و خوشه‌های تجاری وزن‌دهی مناسب‌تری بیابند. ارزیابی تجربی بر روی یک مجموعه داده شبیه‌سازی شده شامل ۱۴۸۰ کارت بانکی، ۳۵۰ پایانه پذیرنده در ۸ صنف اقتصادی و ۰۰۰,۳۵ تراکنش نشان می‌دهد که روش پیشنهادی به شاخص اطلاعات متقابل نرمال‌شده (NMI) معادل ۰.۸۶۷ و شاخص رند تعدیل‌شده (ARI) معادل ۰.۸۸۵ دست می‌یابد؛ این نتایج نسبت به مدل جدولی RFM بهبود قابل‌ملاحظه‌ای را نشان می‌دهند و در عین حال عملکردی هم‌سطح با تجزیه ماتریسی SVD ثبت می‌کنند، با این مزیت که امکان تلفیق ویژگی‌های گره‌ای و استنتاج بر ساختار رابطه‌ای را فراهم می‌سازد.

کلمات کلیدی

پرداخت الکترونیک، کشف مشتری، شبکه عصبی گراف، انحنای فرم-ریچی، خودرمزگذار گراف، بازنمایی رفتار مالی

محدودیتی‌هایی است: نخست آنکه مشتریان را مستقل از یکدیگر فرض می‌کند و ساختار ارتباطات شبکه‌ای را نادیده می‌گیرد؛ دوم، با تجمع مبالغ، تمایز کیفی میان یک تراکنش سنگین سرمایه‌ای با مجموعه‌ای از تراکنش‌های خرد روزمره از بین می‌رود؛ و سوم، شباهت‌های غیرمستقیم ناشی از الگوهای مشترک مصرف در اصناف مختلف در فضای اقلیدسی RFM منعکس نمی‌شود.

یادگیری عمیق بر روی گراف (GNN) امکان استخراج هم‌زمان الگوها از ویژگی‌های گره و ساختار توپولوژیک شبکه را فراهم می‌سازد [2,10]. با این وجود، در شبکه‌های تراکنشی پرداخت، انتشار یکنواخت پیام‌ها می‌تواند با پدیده تراکم اطلاعات در گره‌های پرتراکم و پل‌های گلوگاهی روبه‌رو شود. در این پژوهش، چارچوبی تحت عنوان HG-CAN با تکیه بر انحنای گسسته فرم-ریچی پیشنهاد می‌شود که در آن از انحنای موضعی یال‌ها برای تنظیم ضرایب توجه در شبکه عصبی گراف استفاده می‌گردد. اهداف و مشارکت‌های این مقاله به شرح زیر است:

۱- مقدمه

تراکنش‌های کارتی در شبکه پرداخت الکترونیک از مهم‌ترین منابع داده‌های رفتاری به شمار می‌روند. هر تراکنش در لحظه ثبت دست‌کم پنج مؤلفه را در بر دارد: مشخصه کارت بانکی، ارزش ریالی تراکنش، شناسه پایانه پذیرنده، زمان وقوع و رسته فعالیت صنف اقتصادی (مانند تلافروشی، سوپرمارکت، آه‌ن‌آلات، خدمات مسافرتی و پزشکی). در سامانه‌های متداول گزارش‌گیری بانکی، این سوابق بیشتر برای تسویه مالی و گزارش‌های آماری جمع‌بندی می‌شوند و از ساختار ارتباطی میان آن‌ها استفاده محدودی صورت می‌گیرد.

الگوی رایج بخش‌بندی مشتریان در صنعت بانکداری، مدل تازگی، تکرار و ارزش مالی (RFM) است [5]. این الگو با خلاصه‌سازی داده‌ها در چند متغیر اسکالر و اعمال الگوریتم‌هایی نظیر K-Means پیاده‌سازی می‌شود. این رویکرد دارای

- **cast_name**: نام صنف اقتصادی پذیرنده (شامل طلافروشی، سوپرمارکت، آهن‌آلات، آژانس مسافرتی، خدمات پزشکی و ...).

هدف مسئله، یادگیری یک نگاشت بدون نظارت از فضای کارت‌های پرداخت به فضای بازنمایی پیوسته $d^R \in \mathbb{Z}_U$ است، به طوری که کارت‌های دارای الگوی تراکنشی و هم‌پذیرندگی مشابه در فضای نهفته به یکدیگر نزدیک باشند.

1-3- مجموعه داده شبیه‌سازی شده

به دلیل الزامات محرمانگی داده‌های بانکی، این پژوهش از یک مجموعه داده شبیه‌سازی شده چندعاملی بهره می‌برد. این مجموعه شامل 35,000 تراکنش، 1,480 کارت پرداخت فعال، 350 پایانه پذیرنده در 8 صنف اقتصادی در یک بازه زمانی ۹۰ روزه است. مبالغ تراکنش‌ها بر اساس توزیع لاگ‌نرمال با میانگین و پراکندگی وابسته به صنف نمونه‌برداری شده‌اند. در فرآیند شبیه‌سازی، کارت‌ها به ۵ دسته ترجیحی رفتاری با توزیع‌های احتمالی مشخص خرید در اصناف تخصیص یافته‌اند؛ این شناسه‌ها صرفاً به عنوان برچسب‌های مبنای (Ground-Truth) جهت ارزیابی بیرونی با سنج‌های NMI و ARI محفوظ مانده‌اند و مدل در فرآیند آموزش کاملاً بدون نظارت (Unsupervised) عمل کرده است.

4- چارچوب معماری پیشنهادی (HG-CAN)

چارچوب معماری پیشنهادی از چهار لایه پیوسته و مستقل عملیاتی تشکیل گردیده است (شکل (1)): (1):



شکل (1): معماری چهارلایه چارچوب پیشنهادی HG-CAN

- ارائه یک معماری چهارلایه برای تبدیل رکوردهای تراکنش به بازنمایی‌های برداری و خوشه‌های رفتاری قابل‌تفسیر؛
- استفاده از انحنای گسسته فورمن-ریچی به همراه شباهت اصناف جهت تعدیل ضرایب مکانیزم توجه چندسدر در خودرمزگذار گراف؛
- به‌کارگیری تابع زیان سه‌گانه بدون نظارت شامل بازسازی پیوندها، بازسازی ویژگی‌های گره و تنظیم انحنای؛
- ارزیابی تجربی و مقایسه شفاف نتایج با مدل سنتی RFM و خط‌مبنای تجزیه ماتریسی SVD بر روی داده‌های شبیه‌سازی شده.

ادامه مقاله بدین ترتیب تنظیم شده است: بخش 2 کارهای مرتبط را مرور می‌کند؛ بخش 3 به توصیف داده و فرمول‌بندی مسئله اختصاص دارد؛ بخش 4 چارچوب پیشنهادی را تشریح می‌نماید؛ بخش 5 ارزیابی تجربی و تحلیل نتایج را گزارش می‌کند و بخش 6 به نتیجه‌گیری می‌پردازد.

2- کارهای مرتبط

1-2- بخش‌بندی مشتریان بر پایه RFM

مدل RFM از بازاریابی مستقیم به بانکداری راه یافته و معمولاً با الگوریتم‌هایی مانند K-Means ترکیب می‌شود [5]. این رویکرد ارزان و تفسیرپذیر است، اما مشتری را به چند عدد تجمعی تقلیل می‌دهد و از اطلاعات صنف و رابطه میان مشتریان استفاده نمی‌کند. تجزیه ماتریس مشتری-صنف گامی به‌سوی استفاده از این اطلاعات است، ولی بازنمایی خطی می‌سازد و ویژگی‌های رفتاری گره‌ها را مستقیماً وارد نمی‌کند.

2-2- یادگیری بازنمایی روی گراف

روش‌هایی مانند node2vec [3]، شبکه کانولوشنی گراف (GCN) [7]، GraphSAGE [4] و شبکه توجه گراف (GAT) [8] بازنمایی گره‌ها را از ساختار گراف می‌آموزند. خودرمزگذار گراف تغییرگون [6] این ایده را به یادگیری بی‌نظارت گسترش داده است. این خانواده روش‌ها در شبکه‌های مالی بیشتر برای تشخیص ناهنجاری به کار رفته‌اند [9]. آنچه این مقاله اضافه می‌کند، کاربرد آن‌ها در کشف مشتری و ترجمه خروجی به پرسونا و شاخص‌های سازمانی است.

3- داده و صورت‌بندی مسئله

دفتر کل تراکنش‌های پرداخت به صورت دنباله‌ای از رکوردهای مالی $T = \{t_1, t_2, \dots, t_M\}$ نمایش داده می‌شود که در آن هر رکورد t_m شامل پنج فیلد استاندارد است:

- **pan**: شناسه کارت بانکی به صورت پوشانده‌شده (Masked PAN) جهت رعایت الزامات حریم خصوصی؛
- **amount**: ارزش مالی تراکنش بر حسب ریال؛
- **merchant_id**: شناسه یکتای پایانه پذیرنده یا درگاه پرداخت؛
- **create_date**: زمان ثبت تراکنش در سوییچ؛

5- ارزیابی تجربی و نتایج


5-1- مقایسه با روش‌های خطمبنا

عملکرد روش پیشنهادی HG-CAN با مدل متداول RFM و تجزیه ماتریسی SVD مقایسه گردید. نتایج در جدول (1) خلاصه شده است.

جدول (1): مقایسه نتایج خوشه‌بندی روش‌ها بر روی داده‌های شبیه‌سازی‌شده

روش / معماری	NMI	ARI	Silhouette	Davies-Bouldin
Classical Tabular RFM K-Means +	0.175	0.048	0.410	0.824
Bipartite Matrix (SVD) Factorization	0.867	0.885	0.286	1.332
Proposed HG-CAN (روش پیشنهادی)	0.867	0.885	0.192	1.906

تحلیل داده‌های جدول (1) نشان می‌دهد که مدل سنتی RFM به دلیل تکیه انحصاری بر متغیرهای تجمیعی و فقدان اطلاعات رابطه‌ای اصناف، شاخص‌های NMI معادل 0.175 و ARI معادل 0.048 را ثبت کرده است. روش‌های مبتنی بر ساختار شبکه و صنف (شامل SVD و HG-CAN) نسبت به خطمبنا RFM عملکرد بالاتری در شاخص‌های NMI و ARI نشان می‌دهند. با این حال، مقایسه روش پیشنهادی با خطمبنا SVD نشان می‌دهد که هر دو روش در شاخص‌های NMI و ARI عملکردی بسیار نزدیک به هم دارند (NMI حدود 0.867 و ARI حدود 0.885). این تشابه نشان می‌دهد که بخش عمده‌ای از تفکیک‌پذیری در این مجموعه داده ناشی از اطلاعات موجود در ماتریس تعاملات دویخشی کارت-صنف است. مزیت روش HG-CAN در انعطاف‌پذیری آن برای گنجاندن هم‌زمان ویژگی‌های آماری غیرخطی گره‌ها (مانند آن‌تروپی شانون و چولگی مبالغه) و تحلیل ساختار شبکه‌ای نهفته است، هر چند که شاخص‌های Silhouette و Davies-Bouldin برای SVD فشاردگی هندسی بیشتری را نشان می‌دهند (شکل (2)).



شکل (2): نمودار مقایسه معیارهای ارزیابی خوشه‌بندی

4-1- لایه 1: دریافت و مهندسی ویژگی‌های رفتاری

در این لایه، تراکنش‌ها پس از اعمال پوشش امنیتی روی کارت‌ها، تجمیع شده و یک بردار ویژگی ۱۶ بعدی برای هر کارت u استخراج می‌گردد. این ویژگی‌ها شامل هشت آماره مالی و زمانی (مجموع مبالغ، میانگین، انحراف معیار، لگاریتم تعداد، تازگی، ضریب چولگی، شاخص تمرکز صنف و آن‌تروپی شانون اصناف) به همراه هشت مؤلفه نسبت توزیع تراکنش در هر یک از هشت صنف اقتصادی است.

4-2- لایه 2: نگاشت ابرگراف و محاسبه انحنای فرم-ریچی

تعاملات کارت‌ها و پایانه‌های پذیرندگی در قالب یک ابرگراف دویخشی $(E, V_{\text{merch}}, V_{\text{card}}) = H$ تعریف می‌شود. با اعمال تصویرسازی وزن‌دار کسینوسی بر روی ماتریس پروفایل اصناف، شبکه کارت-کارت با ماتریس مجاورت A تشکیل می‌شود. سپس برای هر یال $(v, u) = e$ ، انحنای گسسته فرم-ریچی $F(v, u)$ از رابطه (1) محاسبه می‌گردد:

$$F(u, v) = [4 - d(u) - d(v) + 3 \cdot \Delta(u, v)] / \sqrt{d(u) \cdot d(v)} \quad (1)$$

که در آن $d(u)$ درجه گره u و $\Delta(u, v)$ تعداد مثلث‌های مشترک تشکیل‌شده روی یال (v, u) است. انحنای منفی بیانگر یال‌های پل‌ساز میان جوامع و انحنای مثبت نشانگر ساختارهای متراکم درون‌خوشه‌ای است.

4-3- لایه 3: خودرمزگذار توجه‌محور هندسی (HG-CAN)

رمزگذار شبکه از لایه‌های توجه‌گراف مجهز به تنظیم انحنا تشکیل شده است. در سر k ام توجه، ضریب اهمیت یال از رابطه (2) به دست می‌آید:

$$\alpha_{uv}^{(k)} = \text{softmax}_v(\text{LeakyReLU}(a_k^T [W_k h_u \parallel W_k h_v] + \gamma_k \cdot \tanh(F(u, v)) + \beta_k \cdot \ln(1 + w_{uv}))) \quad (2)$$

که در آن W_k ماتریس نگاشت خطی، a_k بردار پارامتر توجه، $F(u, v)$ انحنای فرم-ریچی، w_{uv} شباهت کسینوسی اصناف، و γ_k و β_k ضرایب اسکالر یادگرفتنی هستند. آموزش شبکه با تابع زیان سه‌گانه خودنظارتی (رابطه (3)) به صورت انتها-به-انتها انجام می‌پذیرد:


$$L = L_{\text{link}} + \lambda_1 \cdot L_{\text{attr}} + \lambda_2 \cdot L_{\text{curv}} \quad (3)$$

که در آن L_{link} خطای بازسازی پیوندهای شبکه، L_{attr} خطای بازسازی مشخصه‌های رفتاری و L_{curv} خطای پیش‌بینی انحنای موضعی یال‌هاست؛ ضرایب مصالحه در پیاده‌سازی به ترتیب برابر $\lambda_1 = 0.3$ و $\lambda_2 = 0.1$ تنظیم شده‌اند.

4-4- لایه 4: بخش‌بندی و تفسیر الگوها


بردارهای تعبیه ۳۲ بعدی z_u با الگوریتم‌های خوشه‌بندی تفکیک شده و هم‌زمان شاخص‌هایی نظیر آن‌تروپی شانون تنوع سبد خرید و ضریب چسبندگی شبکه جهت تحلیل کاربردی استخراج می‌گردند.





شکل (4): نقشه حرارتی توزیع تراکنش‌های هر پرسونا در اصناف تجاری (درصد)

بررسی خوشه‌ها نشان می‌دهد که خوشه تجار آهن و مصالح با میانگین تراکنش ۳۶.۸ میلیون ریال بیشترین ارزش ریالی را دارد و خوشه طلا با میانگین ۱۷.۴ میلیون ریال در رتبه بعدی قرار دارد. خوشه‌های گردشگری، خدمات سلامت و خواروبار نیز بر اساس مبالغ و بسامد خرید تفکیک شده‌اند. شکل (5) تفاوت ابعاد رفتاری این خوشه‌ها را در نمودار راداری مصورسازی می‌نماید.



شکل (5): پروفایل ویژگی‌های چندگانه پرسونا‌های سازمانی کشف‌شده

6- نتیجه‌گیری


در این پژوهش چارچوب HG-CAN برای استخراج بازنمایی رفتار تراکنشی از سوابق پرداخت مبتنی بر شبکه عصبی گراف و انحنای فرم-ریچی مورد ارزیابی قرار گرفت. نتایج بر روی داده‌های شبیه‌سازی‌شده عملکرد بالاتری نسبت به خط‌مبنای RFM در شاخص‌های NMI و ARI نشان داد. همچنین مقایسه نشان داد

2-5. ویژگی‌های خوشه‌های کشف‌شده

جدول (2) مشخصات پنج خوشه استخراج‌شده را با صنف غالب و میانگین مبلغ تراکنش گزارش می‌کند.

جدول (2): مشخصات خوشه‌های رفتاری استخراج‌شده توسط چارچوب

کد	عنوان پرسونا	تعداد کارت	میانگین مبلغ (ریال)	صنف غالب
0	تجار و عمده‌فروشان آهن و مصالح صنعتی	289	829,36280	آهن‌آلات و مصالح صنعتی
1	مایحتاج روزمره و مصرف خانوار	295	804,3442	سوپرمارکت و خواروبار
2	سرمایه‌گذاران طلا و کالای لوکس	299	385,17031	طلافروشی
3	مسافران و گردشگران پریمیوم	299	432,10221	اژانس مسافرتی و گردشگری
4	مصرف‌کنندگان خدمات پزشکی و سلامت	298	051,4956	خدمات پزشکی و داروخانه



شکل (3): گراف هم‌رخدادی و بازنمایی دوبعدی کارت‌های بانکی با تفکیک پرسونا



که عملکرد تفکیک مدل پیشنهادی با روش خطی SVD بر روی این داده‌ها در یک سطح قرار دارد. از محدودیت‌های این مطالعه می‌توان به اتکا به داده‌های شبیه‌سازی شده و عدم آزمون بر روی تنوع رفتاری داده‌های واقعی شبکه پرداخت اشاره کرد. تحقیقات آتی باید اعتبارسنجی مدل را بر روی مجموعه‌های داده واقعی و در شرایط توزیع‌های نامتعادل رفتاری دنبال نمایند.

مراجع

- [1] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, E. Lefebvre, "Fast unfolding of communities in large networks", *Journal of Statistical Mechanics: Theory and Experiment*, Vol. 2008, No. 10, P10008, 2008.
- [2] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam, P. Vandergheynst, "Geometric deep learning: Going beyond Euclidean data", *IEEE Signal Processing Magazine*, Vol. 34, No. 4, pp. 18-42, 2017.
- [3] A. Grover, J. Leskovec, "node2vec: Scalable feature learning for networks", *Proc. 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining*, pp. 855-864, 2016.
- [4] W. L. Hamilton, R. Ying, J. Leskovec, "Inductive representation learning on large graphs", *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pp. 1024-1034, 2017.
- [5] A. M. Hughes, *Strategic Database Marketing*, 3rd ed., McGraw-Hill, 2005.
- [6] T. N. Kipf, M. Welling, "Variational graph auto-encoders", *NIPS Workshop on Bayesian Deep Learning*, 2016.
- [7] T. N. Kipf, M. Welling, "Semi-supervised classification with graph convolutional networks", *Proc. 5th Int. Conf. on Learning Representations (ICLR)*, 2017.
- [8] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio, "Graph attention networks", *Proc. 6th Int. Conf. on Learning Representations (ICLR)*, 2018.
- [9] M. Weber, G. Domeniconi, J. Chen, D. K. I. Weidele, C. Bellei, T. Robinson, C. E. Leiserson, "Anti-money laundering in Bitcoin: Experimenting with graph convolutional networks for financial forensics", *KDD Workshop on Anomaly Detection in Finance*, 2019.
- [10] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, P. S. Yu, "A comprehensive survey on graph neural networks", *IEEE Transactions on Neural Networks and Learning Systems*, Vol. 32, No. 1, pp. 4-24, 2021.

